Введение

С 2015 года Банк России перешел к режиму таргетирования инфляции, где в качестве основной цели проводимой денежно-кредитной политики объявлено поддержание годовой инфляции вблизи 4%. В качестве индикатора инфляции используется индекс потребительских цен (ИПЦ). Он показывает изменение стоимости потребительской корзины среднего российского домохозяйства. Прогнозы инфляции (изменения ИПЦ) в краткосрочном и долгосрочном периодах играют важную роль при принятии решений центральным банком в рамках осуществляемой денежно-кредитной политики. Также данные прогнозы влияют на формирование ожиданий аналитиков, фирм и домашних хозяйств, которые транслируются в принимаемые ими экономические решения: определение уровня цен и зарплат, планирование инвестиций, решения о потреблении и сбережениях и др. (Bernanke B. S, 2007). Соответственно, высокая точность прогнозов инфляции может способствовать более эффективному проведению коммуникационной политики и, вследствие этого, меньшим издержкам Банка России для устойчивого поддержания инфляции вблизи заявленной цели.

Обзор литературы

В рамках задачи прогнозирования инфляции по индексу потребительских цен (ИПЦ) в качестве бенчмарков используются как традиционные эконометрические модели, такие как наивный прогноз RW, AR(1), ARIMA, ARIMAx, SARIMA, методы регуляризованной регрессии Ridge и LASSO регрессии, так и другие эконометрические подходы, продемонстрировавшие высокую точность прогнозирования именно в контексте инфляции. Например, Stock J. H., Watson M. W. показали, что модель стохастической волатильности с ненаблюдаемыми компонентами (UCSV) показывает высокую точность прогнозов инфляции в США (Stock J. H., Watson M. W., 2008). Особенность данной модели состоит в том, что она выделяет у временного ряда инфляции две ненаблюдаемые компоненты: трендовую и циклическую для прогнозирования. Кроме того, в качестве бенчмарка используется кривая Филлипса как расширения базовой авторегрессионной модели, где учитывается влияние уровня безработицы на инфляцию наряду с ее прошлыми значениями.

Среди методов машинного обучения в рамках задачи прогнозирования уровня инфляции в России (изменение уровня ИПЦ)

высокую точность прогнозов на горизонте 6, 12 месяцев показали модели MLP (многослойный персептрон) и SVM (метод опорных векторов) на месячных данных с 2002 до 2018 года (Павлов, 2020). Однако авторы в разделе, посвященному кросс-валидации и обучению, указывают, что выборка случайным образом разбивается на 10 фолдов. Такой подход может быть применен относительно кросс-секционных данных, но недопустим при прогнозировании временных рядов, что ставит под вопрос корректность полученных авторами результатов.

Chakraborty, Joseph при прогнозировании поквартальной инфляции в Великобритании применяют кросс-валидацию с расширяющимся окном, где на каждом шаге строится прогноз на 2 года (8 кварталов) вперед (Chakraborty C., Joseph A., 2017). Кроме того, авторы разбивают тестовую выборку на две части: до глобального финансового кризиса (2005Q1 – 2010Q3) и после (2010Q3 – 2015Q4). В качестве границы авторы используют 3 квартал 2010 года, так как влияние кризиса на макроэкономические переменные происходило с лагом. В результате, авторы получают, что предкризисный период инфляция в Великобритании лучше всего предсказывается комбинацией прогнозов SVM и DFNN (Deep Feedforward Neural Network), а в послекризисный период – моделью случайного леса.

В исследовании Букиной и Кашина о прогнозировании региональной инфляции в субъектах Приволжского федерального округа с использованием данных с января 2010 г. по декабрь 2022 г. Random Forest также показал наиболее точные прогнозы инфляции на горизонте в 24 месяца, что соотносится с результатами Chakraborty, Joseph (Букина Т. В., Кашин Д. В., 2024). Однако на более коротком горизонте прогнозирования в 3, 6 месяцев градиентный бустинг показывает лучшее качество. Стоит отметить, что бенчмарк модель ARIMAX с включением курса доллара как экзогенной переменной и различной спецификацией в зависимости от региона демонстрирует более точные прогнозы на 1 и 12 месяцев вперед. Метод опорных векторов для рассматриваемых горизонтов прогнозирования показывает точность прогнозов хуже или сопоставимую с бенчмарком.

В недавнем исследовании Sengupta S., Chakraborty T., Singh S. K. применяют различные методы машинного обучения для прогнозирования инфляции на горизонтах в 12 и 24 месяцев в странах БРИКС (Sengupta S., Chakraborty T., Singh S. K., 2024). В качестве данных авторами

используются месячные данные ИПЦ с января 2003 по ноябрь 2021 года. Авторы применяют следующие ML-модели: DeepAR, N-Beats, XGBoost, ARNNx (Autoregressive neural network with exogenous variable), TFT (temporal fusion transformer). Также авторы предлагают модель FEWNet (Filtered Ensemble Wavelet Neural Network).

Алгоритм FEWNet выглядит следующим образом. Во-первых, применяется вейвлетное разложение временного ряда инфляции для представления его в качестве суммы K функций с высокой частотой (краткосрочные колебания) и одной функции с низкой частотой (долгосрочные колебания). Это помогает уменьшить «шум» нестационарного ряда для получения более точных прогнозов. Затем используется фильтр Ходрика–Прескотта для выделения циклической компоненты у экзогенных переменных, отражающих неопределенность. После этого применяется ансамблевая нейросеть ARNNx, где для каждой из K+1 функций строится отдельная нейронная сеть. Это позволяет сделать прогноз на 1 месяц для каждой компоненты ряда инфляции, после чего эти прогнозы суммируются для получения итогового прогноза. Для построения многошаговых прогнозов авторы используют итеративное (рекурсивное) прогнозирование, при котором предсказания на предыдущих шагах подаются в модель как входные данные для следующих прогнозов. Процесс повторяется, пока не будет получен прогноз на 12 или 24 месяца вперед.

Относительно результатов прогнозирования уровня инфляции в России, бенчмарк-модель AR(1) показала наиболее точные прогнозы как на горизонте 12 месяцев, так и 24 месяца. Однако после середины 2021 года модели FEWNet и XGBoost незначительно превосходили AR(1) по точности прогнозов согласно метрикам RMSE и MASE. Сопоставимую с бенчмарк-моделями точность прогнозов показали N-Beats и DeepAR.

В качестве эконометрических методов для прогнозирования инфляции применяются VAR, TVP-VAR, BVAR (Barkan O. et al., 2023; Демешев Б. Б., Малаховская О. А., 2016). Андрей Андреев в исследовании предлагает метод комбинирования прогнозов VAR, BVAR и МНК-регрессии для прогнозирования инфляции (Андреев А., 2016).

Данные

В качестве объясняемой переменной используются месячные данные индекса потребительских цен на товары и услуг, рассчитанные Росстатом,

с января 2015 года до февраля 2025 года (121 наблюдение) [15]. ИПЦ измеряется как процентное изменение цен на конец предыдущего месяца. Был выбран этот временной промежуток, так как Банком России номинальный якорь в 4% годовой инфляции был установлен в январе 2015 года. В качестве дополнительных переменных были использованы такие макроэкономические показатели, как денежный агрегат M2 (млрд. рублей) [13], прямой валютный курс USD/RUB [12] и прокси для ВВП индекс промышленного производства (% к предыдущему месяцу) [16] с ежемесячной частотой публикации данных, в отличие от поквартальной для ВВП (Демешев Б. Б., Малаховская О. А., 2016; Павлов, 2020). В качестве источников этих месячных данных выступали базы данных Росстата, Банка России и Statista. Также увеличение точности прогнозов инфляции достигается при включении показателей, связанных с денежным и финансовыми рынками (Демешев Б. Б., Малаховская О. А., 2016). Нами были использованы среднемесячные данные по ставкам на межбанковском рынке, MIACR (% годовых) [17] и индекс Московской биржи (рубль) [19].

Кроме того, многие исследования продемонстрировали, что включение переменных, отражающих уровень неопределенности, может улучшить точность прогнозов инфляции (Sengupta S., Chakraborty T., Singh S. K., 2024). В российском контексте прокси неопределенности является индекс волатильности российского рынка (RVI) [14], рассчитываемый Московской биржей (Petrova, D. and Trunin, P., 2023). Также, согласно макроэкономической теории, на инфляцию влияют ожидания экономических агентов относительно уровня цен. Наиболее сильный прирост точности прогнозов дает включение инфляционных ожиданий аналитиков (Banbura M., Leiva-León D., Menz J. O., 2021). Однако они публикуются институтом “Центр развития” НИУ ВШЭ лишь с квартальной периодичностью. Можно было бы провести преобразованию данного временного ряда в ряд с более высокой частотой с помощью метода Чоу-Лин. Однако мы решили использовать в качестве переменной ценовые ожидания фирм на следующий месяц по данным Банка России [18]. Данные были доступны только с сезонной корректировкой. Инфляционные ожидания фирм, согласно теории, учитывают факторы спроса, издержек производства, количества рабочей силы и ее стоимости, что предопределяет ценовое поведение предприятий и оказывает влияние на фактическую инфляцию. Отметим, что у нас потенциально может возникнуть проблема “проклятия размерности”, однако в исследованиях по

данной тематике авторами используется похожее как у нас соотношение между числом переменных и наблюдений.

Методы

В качестве эконометрической модели была использована векторная авторегрессия (VAR). В качестве эндогенных переменных использовались: ИПЦ, индекс промышленного производства, валютный курс USD/RUB, инфляционные ожидания фирм и индекс волатильности российского рынка. Для избежания проблем наличия большого количества эндогенных переменных при относительно небольшой выборке, в спецификации модели были отобраны только те переменные, которые имеют причинно-следственную связь с уровнем цен в экономике, а также те, чье включение способствует повышению точности прогнозов. Для построения прогнозов с помощью векторной авторегрессии необходимым условием является стационарность временных рядов, используемых в качестве переменных моделей.

Индекс потребительских цен. В ряде ИПЦ наблюдаются характерные пики в каждом году примерно в январе и июле, что может быть объяснено частым увеличением цен на тарифы ЖКХ, проезд в транспорте и др. в данные периоды. Кроме того, есть выбросы в ряде: значение ИПЦ в марте 2022 года, а также январе 2015 года, что мы учтем путем добавления дамми-переменных на эти даты при спецификации VAR-модели.

Рис.1. График временного ряда ИПЦ

Графики автокорреляционной (ACF) и частной автокорреляционной (PACF) функций показывают статистически значимые коэффициенты для первого лага, после чего значения коэффициентов быстро снижаются до нуля, что может служить потенциальным индикатором стационарности ряда. При этом на графике ACF не статистически значимые коэффициенты автокорреляции для лагов больше второго демонстрируют характерный паттерн, который может свидетельствовать о наличии сезонности.

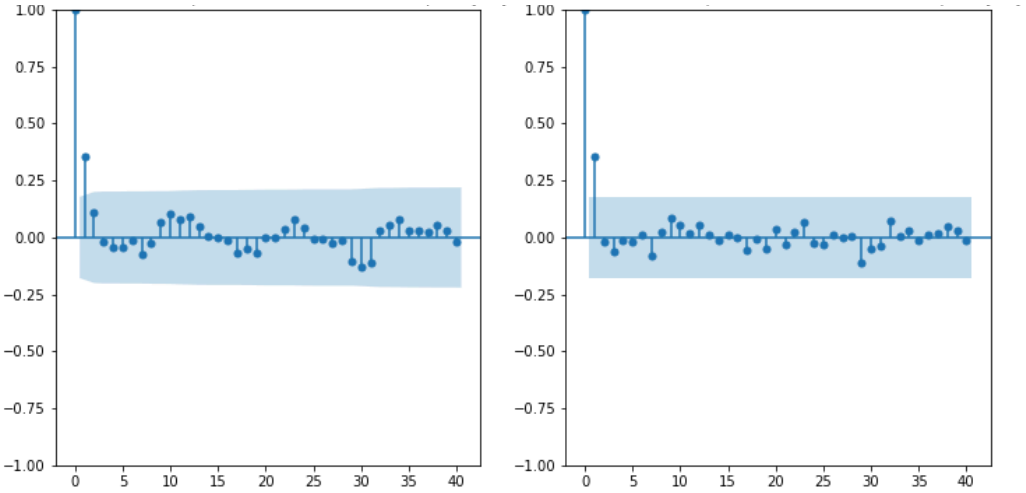

Рис.2. Графики ACF и PACF для временного ряда ИПЦ

Нами были предприняты попытки убрать сезонную компоненту из ряда путем логарифмирования, сезонной декомпозиции с мультипликативной и аддитивной ошибками, взятия 1, 7, 12 разностей. Однако результаты значительно не улучшились, поэтому для сохранения наибольшей информации в данных приняли решение использовать исходный ряд. Кроме того, расширенный тест Дикки-Фуллера (p-value: 1,4e-12) и KPSS тест (p-value: 0,11) показывают, что исходный ряд ИПЦ стационарен на всех адекватных уровнях значимости. Для учета возможной сезонности ИПЦ будут использованы дамми переменные на номер месяца года в модели.

Индекс промышленнного производства. Из графика исходного временного ряда видно, что процесс нестационарен. График ACF также демонстрирует сезонный паттерн в данных, что свидетельствует о его нестационарности. Было проведено логарифмическое преобразование ряда, которое незначительно приблизило ряд к стационарному виду, после чего была взята первая разность. Временной ряд для индекса в результате был приведен к стационарному виду, что показали тесты расширенного Дикки-Фуллера с константой (p-value: 1.e-06) и KPSS (p-value: 0,12).

Однако на графиках преобразованного временного ряда ACF и PACF видно присутствие сезонности (статистически значимые коэффициенты около 12 лага). Но дальнейшие преобразования могут привести к потере информации о природе данных, поэтому наличие сезонности будет учтено при помощи включения дамми переменных.

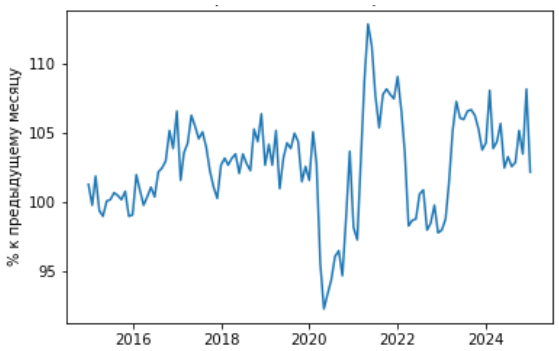

Рис.3. График исходного временного ряда индекса промышленного производства

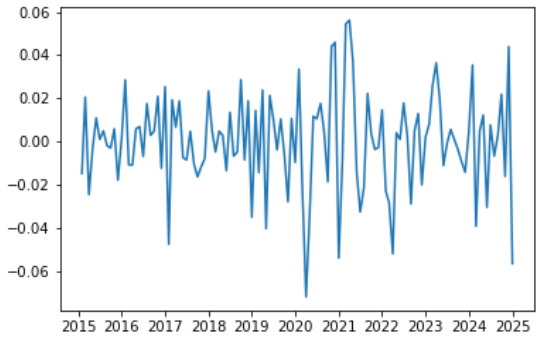

Рис.4. График временного ряда индекса промышленного производства после логарифмирования, взятия первой разности

<u>Денежный агрегат M2.</u> К временному ряду денежного агрегата M2 была применена логарифмическая трансформация для устранения экспоненциального тренда.

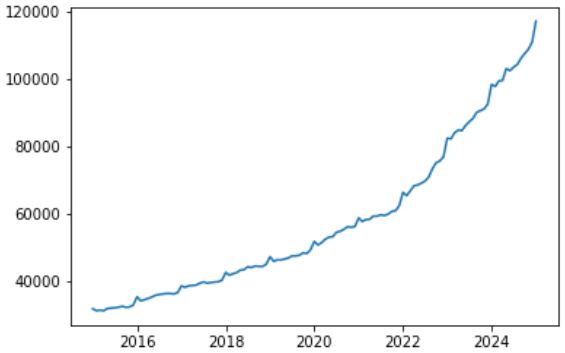

Рис.5. График исходного временного ряда денежного агрегата M2

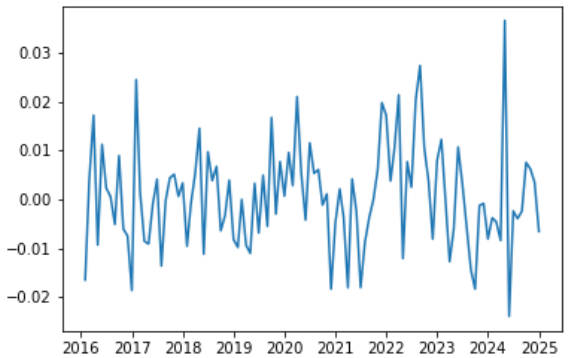

Рис.6. График временного ряда денежного агрегата M2 после логарифмирования, удаления трендовой и сезонной компонент

Далее была удалена трендовая компонента, однако в ряде сохранялась выраженная сезонность, как на графиках ACF и PACF, так и на непосредственно графике временного ряда. Для её устранения была применена сезонная разность с 12-ым лагом. Преобразованный ряд является стационарным как визуально, так и по результатам тестов KPSS

(p-value: 0,13) и расширенного теста Дикки-Фуллера с константой (p-value: 1,8e-05).

Валютный курс USD/RUB. Исходный временной ряд валютного курса нестационарен. К нему была применена логарифмическая трансформация и взятие первой разности. После данных преобразований графики автокорреляционной (ACF) и частной автокорреляционной (PACF) функций не демонстрируют признаков сезонности, а коэффициенты быстро сходятся к нулю, что является косвенным признаком стационарности. Анализ временного ряда выявил наличие выбросов в начале 2022 и 2025 годов, что будет учтено в моделях с помощью дамми-переменных. Статистические тесты KPSS (p-value: 0,11) и расширенный тест Дикки-Фуллера (p-value: 6,4e-16) подтверждают стационарность процесса.

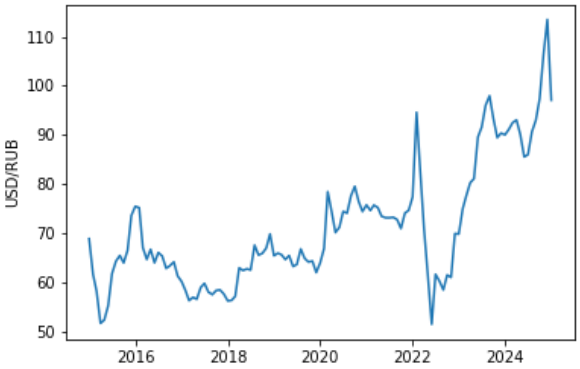

Рис.7. График исходного временного ряда валютного курса USD/RUB

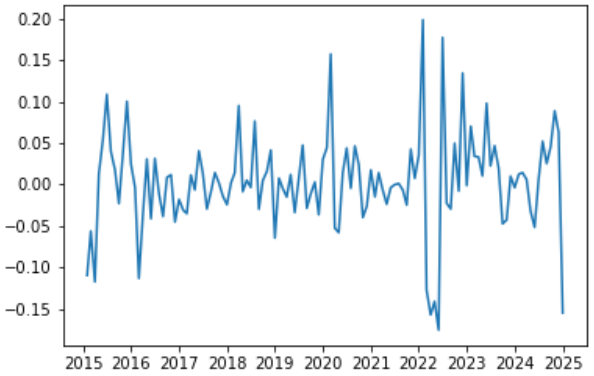

Рис.8. График временного ряда валютного курса после логарифмирования, удаления трендовой и сезонной компонент

Инфляционные ожидания фирм. Исходный ряд инфляционных ожиданий нестационарен, а также демонстрирует восходящий тренд после 2020 года. Было применено логарифмическое преобразование к ряду и устранение данного тренда. Однако после этого ряд оставался все еще нестационарным, поэтому была взята первая разность. По результатам тестов Дикки-Фуллера (p-value: 6,5e-12) и KPSS (p-value: 0,12) можно сделать вывод, что преобразованный временной ряд инфляционных ожиданий фирм является стационарным. Однако на графике временного ряда наблюдаются пики в начале 2019, 2020 и 2022 годов, что может указывать на наличие структурных изменений или аномалий в данных. Кроме того, график частной автокорреляционной функции (PACF) показывает наличие статистически значимого коэффициента на 24-м лаге. Однако дополнительные преобразования ряда могут привести к потере

информации, поэтому для учета выбросов в модели будут добавлены дамми-переменные для соответствующих периодов.

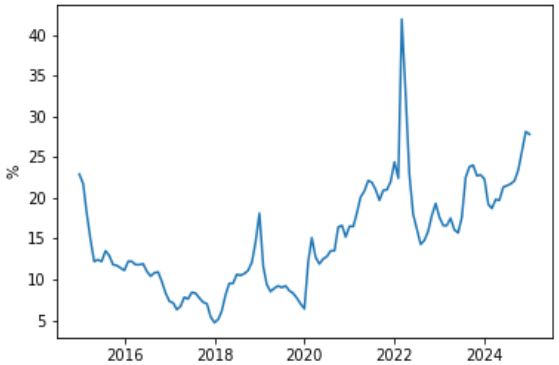

Рис.5. График исходного временного ряда инфляционных ожиданий фирм

Рис.4. График временного ряда инфляционных ожиданий форм после логарифмирования, удаления трендовой и сезонной компонент

Индекс волатильности российского рынка (RVI). Временной ряд RVI был приведен к стационарному виду с помощью логарифмического преобразования, взятия первой разности и удаления сезонной компоненты путем взятия сезонной разности с лагом 12. Результаты тестов KPSS (p-value: 0,11) и Дикки-Фуллера (p-value: 5e-07), а также графики PACF и ACF подтверждают стационарность преобразованного ряда. Однако на графике временного ряда наблюдаются значительные пики в начале 2020, 2022 и 2023 годов, что может свидетельствовать о структурных изменениях или выбросах. Для их учета в спецификацию модели будут добавлены дамми-переменные.

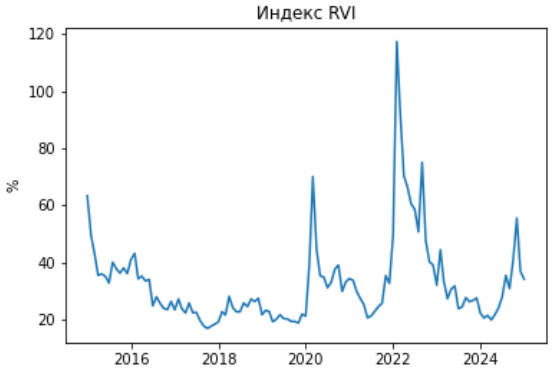

Рис.5. График исходного временного ряда индекса волатильности российского рынка

Рис.4. График временного ряда индекса RVI после логарифмирования, удаления трендовой и сезонной компонент.

По результатам предобработки данных статистические тесты показали стационарность временных рядов. Однако нами было замечено,

что необходимо включить дамми-переменные на следующие даты в спецификацию модели помимо эндогенных переменных: 2022-03-01, 2021-03-01, 2022-02-01. Заметим, что для приведения рядов к стационарному виду было использование взятия разностей, поэтому наблюдений стало 108. Для подбора оптимального порядка VAR модели использовались информационные критерии AIC, BIC, HQIC (Hannan-Quinn Criterion), FPE (Final Prediction Error). Максимальное количество лагов было установлено равным 10, из-за относительно небольшой выборки. Минимизация данных критериев происходила на обучающей выборке (78 наблюдений, с марта 2016 года по июль 2022 года).

Число лагов	AIC	BIC	FPE	HQUIC
0	-30.35	-30.16*	6.587e-14	-30.27
1	-30.97*	-29.62	3.550e-14*	-30.44*
2	-30.78	-28.27	4.406e-14	-29.78
3	-30.53	-26.87	5.990e-14	-29.08
4	-30.34	-25.52	8.111e-14	-28.43
5	-30.25	-24.27	1.087e-13	-27.87

Таблица 1. Значения информационных критериев для первых 5 лагов.
Примечание: * — минимальное значение информационного критерия

В результате AIC, BIC принимают отрицательные значения, что показывает высокое значение функции правдоподобия. Наименьшие значения для информационных критериев AIC (-30.97), HQIC (-30.44), FPE (3.550e-14) получаются при 1 лаге, а для BIC (-30.16) при отсутствии лагов. Учитывая, что AIC, HQIC и FPE указывают на первый лаг, а BIC – на нулевой, в целях баланса между точностью прогнозирования и сложностью модели был выбран первый порядок VAR.

Сначала была оценена модель VARX(1), в которой экзогенными переменными выступали сезонные переменные. Однако при оценке модели оптимизация максимального правдоподобия не сходилась. Это может быть связано с недостаточным количеством наблюдений при большом числе эндогенных переменных, а также с включением экзогенных переменных. Такой результат является негативным сигналом,

что указывает на возможную проблему переобучения и перепараметризации. Также важно провести тест о наличии автокорреляции в данных, чтобы убедиться в правильности выбора включения только одного лага переменных вместо двух. Q-тест Льюнг-Бокса на автокорреляцию показывает, что ошибки первого лага распределены независимо, в то время как для второго и третьего лагов нулевая гипотеза об отсутствии серийной корреляции между остатками отвергается на уровне значимости 5%. В связи с этим было принято решение для прогнозирования использовать модель VAR(1), с учетом, что все временные ряды были предварительно приведены к стационарному виду. Для VAR(1) нулевая гипотеза Q-теста Льюнг-Бокса об отсутствии автокорреляции не отвергается на 1%, 5%, 10% относительно всех лагов с 1 по 12. Это показывает адекватность выбранного порядка VAR модели.

После этого приступаем к прогнозированию с использованием модели VAR(1) и кросс-валидации с расширяющимся окном, состоящей из 5 фолдов. Обучалась модель, как ранее говорили, на данных с марта 2016 года по июль 2022 года (78 точек). Поскольку количество наблюдений сократилось после преобразований (было 121 наблюдение, стало 108 точек) для приведения рядов к стационарному виду, что обязательное условие для применения VAR моделей, чтобы получить адекватные результаты оставляем 30 месяцев для проверки точности прогнозов (с августа 2022 года по февраль 2025 года), с горизонтом 6 месяцев. То есть строим прогноз на 6 месяцев вперед. После получения прогнозов для первого шага (прогноз на 6 месяцев вперед из июля 2022 года) они добавляются в обучающую выборку, после строятся прогнозы на следующие 6 месяцев. В качестве метрик точности прогнозов ИПЦ используем RMSE и MAPE, поскольку для прогнозируемой переменной значения значительно больше нуля, и проблем при расчете значений MAPE не возникнет. Среднее значение RMSE по 5 фолдам составило 0,65, а среднее значение MAPE – 0,56%. Значение метрик RMSE и MAPE для VAR(1) модели больше, чем у моделей бенчмарков. Это может быть вызвано все-таки проблемами соотношения числа эндогенных переменных модели и количества наблюдений.

В качестве бенчмарк-моделей нами были выбраны модели наивного прогноза, AR(1) и ARIMA, которая с помощью функции auto.arima() самостоятельно подобрала значения параметров. Модели также обучались на кросс-валидации с расширяющимся окном на 5 фолдах, с 6 элементами

в тестовой выборке для каждого разбиения. В качестве ML-моделей были выбраны: RandomForest, XGBoost, SVM, MLP, классический градиентный бустинг.

Model	**Average RMSE**	**Average MAPE**
Naive	0.4705	0.4176
AR(1)	0.3738	0.3232
ARIMA	0.3731	0.3227
RandomForest	0.4370	0.3630
XGBoost	0.4800	0.3941
SVM	0.4268	0.3651
MLP	1.6635	1.4508
GBR	0.5029	0.3932

Таблица 2. Усредненные на кросс-валидации значения метрик качеств для моделей по 5 фолдам.

По результатам оценивания качества на кросс-валидации мы пришли к следующим выводам: по MAPE лучшую точность прогнозов показывают autoARIMA, AR(1), RandomForest, по RMSE – AR(1), autoARIMA, SVM. Модели бенчмарки по качеству значительно превосходят ML-модели, такие как, MLP, GBR. Даже наивная модель показывает более точные прогнозы, чем более сложные алгоритмы машинного обучения. Худшие точности прогнозов по кросс-валидации – MLP. Далее мы применили тест Диболда-Мариано для проверки статистической значимости различий в точности прогнозов бенчмарк-моделей с более сложными моделями в целях выяснить, оправдано ли использование более сложных моделей, если простые демонстрируют высокую предсказательную способность и нас устраивает их качество.

Тест Диболда-Мариано показал, что на 5% уровне в большинстве случаев различия в точности прогнозов между моделями-бенчмарками и ML-моделями не являются статистически значимыми. Это означает, что сложные модели не демонстрируют в общем устойчивого и значимого преимущества перед простыми моделями.

Model 1	Model 2	p-value
Naive	VAR	0.1606
Naive	RandomForest	0.4816
Naive	XGBoost	0.0173
Naive	SVM	0.0660
Naive	MLP	0.0000
Naive	GBR	0.1226
AR	VAR	0.0142
AR	RandomForest	0.0558
AR	XGBoost	0.1685
AR	SVM	0.4012
AR	MLP	0.0000
AR	GBR	0.0380
ARIMA	VAR	0.0130
ARIMA	RandomForest	0.0547
ARIMA	XGBoost	0.1668
ARIMA	SVM	0.4123
ARIMA	MLP	0.0000
ARIMA	GBR	0.0379

Таблица 3. Значение p-value, полученные после проведения теста Диболда-Мариано, для всех пар бенчмарк и сложных моделей.

Такие результаты в том числе и соотносятся с выводами исследований из обзора литературы (Sengupta S., Chakraborty T., Singh S. K., 2024). В частности, модели AR и ARIMA показали себя особенно уверенно при сравнении с большинством сложных моделей, включая XGBoost, SVM и

RandomForest, их прогнозы статистически не отличаются по точности. Некоторые исключения всё же были выявлены. Например, при сравнении ARIMA и AR с моделью VAR, p-value в ряде случаев оказалось ниже порогового уровня, что говорит о том, есть статистическая значимая разница в точности моделей, и далее мы можем выбрать ту модель, которая дает лучшее качество для построения прогнозов. Отметим, что присутствует статистически значимая разница в точности прогнозов наивной модели и XGBoost, а также в точности прогнозов наивной модели и MLP. Это говорит о том, что стоит однозначно использовать наивную модель вместо MLP для прогнозов. Однако с XGBoost ситуация неоднозначна, так как по метрике RMSE более точна наивная модель, а по MAPE – XGBoost. Кроме того, тест Диболда-Мариано показал на 5% уровне значимости, что различия в точности прогнозов autoARIMA и GBR статистически значимы, а значит, используем ту модель, которая точнее, это autoARIMA.

Во всех сравнениях с MLP p-value оказывается равным нулю. Это однозначно говорит о том, что существует статистическая разница между различиями этой модели с бенчмарками. Учитывая полученные ранее метрики качества, можно уверенно сказать, что бенчмарк-модели оказались лучше нейросети. Такое может быть связано как с неточным подбором гиперпараметров, так и с тем, что MLP просто не подходит для решения этой задачи, из-за переобучения или сложности временной структуры данных.

Таким образом, сравнив точности прогнозов всех используемых нами ML-моделей и VAR(1) с бенчмарками, можно сделать общий вывод о том, что в данной задаче, прогнозирования ИПЦ, нет необходимости стремиться к использованию сложных моделей машинного обучения, поскольку простые модели временных рядов не уступают им по точности прогнозов. Учитывая простоту настройки и интерпретации, именно модели ARIMA и AR можно рекомендовать как оптимальный выбор. Лишь в отдельных случаях, когда данные обладают выраженными многомерными связями, может оказаться полезным использование VAR, но это скорее исключение, чем правило.

На практике многие исследователи ввиду сложности приведения рядов к стационарному виду добавляют категориальные переменные к имеющимся данным, что улучшает точность прогнозов [20]. Мы решили это изучить, использовав все ряды исходного датасета, а также добавить в

него календарный признак (квартал), дамми-переменную шока на февраль-июль 2022 года, так как есть заметное изменение всех переменных в этот период (происходит структурный сдвиг в экономике), и несколько лагов объясняемой переменной (1, 2, 12). Используется та же кросс-валидация на 5 фолдах с 6 точками в тесте, что и ранее. Цель нашего исследования не изменилась: изучить, как сильно меняются метрики точности RMSE, MAPE для такого набора переменных, а также проверить с помощью теста Диболда-Мариано наличие статистически значимой разницы между точностью прогнозов моделей, обученных на этом датасете. Все модели остаются теми же, кроме VAR. Его решили не использовать, так как среди других используемых нами эконометрических моделей, он имеет наиболее строгие предпосылки.

Model	**Average RMSE**	**Average MAPE**
Naive	0.4705	0.4176
AR(1)	0.3739	0.3232
ARIMA	0.3718	0.3222
RandomForest	0.5626	0.5105
XGBoost	0.3195	0.2685
SVM	0.3450	0.2920
MLP	220.7076	207.2635
GBR	1.0618	0.9078

Таблица 4. Усредненные на кросс-валидации значения метрик качеств для моделей по 5 фолдам.

Сравнение подходов с приведением к стационарному виду рядов и с добавлением признаков показывает, что при стационарности лучшие результаты по RMSE и MAPE показывают простые модели временных рядов — ARIMA и AR(1). При добавлении дополнительных переменных в исходный датасет сильно изменились метрики качества моделей. По результатам оценивания качества на кросс-валидации мы пришли к следующим выводам: XGBoost показал наилучшие результаты среди всех моделей с наименьшими значениями RMSE и MAPE. Хорошую точность

по данным метрикам показал и SVM. ARIMA и AR(1) также показали хорошие результаты, уступая XGBoost, но всё же значительно превосходя другие модели. Наихудшие показатели продемонстрировала модель MLP, что говорит о ее чувствительности к данным временного ряда, важность его стационарности. RandomForest, и GBR показали слабые результаты по сравнению с другими моделями.

Model 1	**Model 2**	**p-value**
ARIMA	RandomForest	0.0547
ARIMA	GBR	0.0379
ARIMA	MLP	0.0000
ARIMA	SVM	0.4123
ARIMA	XGBoost	0.1668
Naive	RandomForest	0.4816
Naive	GBR	0.1226
Naive	MLP	0.0000
Naive	SVM	0.0660
Naive	XGBoost	0.0173
AR(1)	RandomForest	0.0558
AR(1)	GBR	0.0380
AR(1)	MLP	0.0000
AR(1)	SVM	0.4012
AR(1)	XGBoost	0.1685

Таблица 5. Значение p-value, полученные после проведения теста Диболда-Мариано, для всех пар бенчмарк и сложных моделей.

Тест Диболда-Мариано показал на 5% уровне значимости, что в большинстве случаев сложные модели не имеют статистически значимых

преимуществ перед простыми моделями-бенчмарками ARIMA, AR(1), наивная модель. Для пар ARIMA с SVM, XGBoost и RandomForest p-value превышает 0.05, что говорит об отсутствии значимых различий в точности. Исключение составляют пары ARIMA с GBR и MLP, где различия значимы, что указывает более точный прогноз autoARIMA по метрикам качества (RMSE, MAPE). Тест показал, что нет статистически значимых различий в точности прогнозов наивной модель с RandomForest, SVM и GBR. Значит, лучше использовать для прогноза более простую модель – наивную модель. Модель AR(1) также показывает сопоставимую точность со сложными моделями, что неудивительно, учитывая подобранные автоматически параметры для ARIMA.

Список литературы

1. Almosova A., Andresen N. Nonlinear inflation forecasting with recurrent neural networks //Journal of Forecasting. – 2023. – Т. 42. – №. 2. – С. 240-259.
2. Banbura M., Leiva-León D., Menz J. O. Do inflation expectations improve model-based inflation forecasts?. – 2021
3. Barkan O. et al. Forecasting CPI inflation components with hierarchical recurrent neural networks //International Journal of Forecasting. – 2023. – Т. 39. – №. 3. – С. 1145-1162.
4. Chakraborty C., Joseph A. Machine learning at central banks. – 2017.
5. Petrova, D. and Trunin, P. (2023). Estimation of Economic Policy Uncertainty. Russian Journal of Money and Finance, 82(3), pp. 48–61.
6. Sengupta S., Chakraborty T., Singh S. K. Forecasting CPI inflation under economic policy and geopolitical uncertainties //International Journal of Forecasting. – 2024.
7. Stock J. H., Watson M. W. Phillips curve inflation forecasts. – 2008.
8. Андреев А. Прогнозирование инфляции методом комбинирования прогнозов в Банке России // СЕРИЯ ДОКЛАДОВ ОБ ЭКОНОМИЧЕСКИХ ИССЛЕДОВАНИЯХ. - 2016
9. Букина Т. В., Кашин Д. В. Прогнозирование региональной инфляции: эконометрические модели или методы машинного обучения? //Экономический журнал Высшей школы экономики. – 2024. – №. 1. – С. 81-107.
10. Демешев Б. Б., Малаховская О. А. Макроэкономическое прогнозирование с помощью BVAR Литтермана //Экономический журнал Высшей школы экономики. – 2016. – Т. 20. – №. 4. – С. 691-710.
11. Павлов Е. Прогнозирование инфляции в России с помощью нейронных сетей //Деньги и кредит. – 2020. – №. 1. – С. 57-73.
12. Average monthly U.S. dollar (USD) and euro (EUR) exchange rate to Russian ruble (RUB) from January 2008 to January 2025 // Statista URL: https://www.statista.com/statistics/1200821/usd-eur-rub-exchange-rate-monthly/
13. Денежные агрегаты // Банк России URL: https://www.cbr.ru/statistics/macro_itm/dkfs/sr_ma_estim/
14. Индекс RVI // Московская биржа URL: https://www.moex.com/ru/index/RVI

15. Индексы потребительских цен // Росстат URL: https://rosstat.gov.ru/bgd/free/b00_24/isswww.exe/stg/d000/i000860r.htm
16. Промышленное производство // Росстат URL: https://rosstat.gov.ru/enterprise_industrial
17. Среднемесячные фактические ставки по кредитам, предоставленным московскими банками (MIACR, MIACR-IG, MIACR-B) // Банк России URL: https://www.cbr.ru/hd_base/mkr/mkr_monthes/
18. Ценовые ожиданий предприятий // Банк России URL: https://www.cbr.ru/analytics/dkp/inflationary_expectations/Infl_exp_24-12/
19. Индекс МосБиржи // Московская биржа URL: https://www.moex.com/ru/index/IMOEX
20. hse_ts_course // URL: https://github.com/Pyatachokk/hse_ts_course/blob/master/2024-spring/seminars/sem_02_tables.ipynb